EP LEARNING BRASIL SUMMER SCHOOL

Rede Neurais Recorrentes

Rafael Teixeira























Outline

- RNNs
- LSTM
- GRU
- Seq2Seq
- Papers









Por que redes neurais recorrente?











Caso Tesla - 2016







PFASAM





Caso Tesla











Caso Tesla



É possível prever o acidente usando apenas uma imagem?










Sequências

"This morning I took the dog for a walk." Te

Texto



Sinais médicos



Áudio









Sequências - Problemas

- Ordem
 - A comida estava boa, não estava ruim
 - A comida estava ruim, não estava boa
- Dependência de longo prazo
 - O tempo que passei na China foi muito legal e tive a oportunidade de aprender a falar _____.
- Compartilhamento de parâmetros
 - Um acidente pode ocorrer a qualquer momento










Recurrent Neural Networks












Recurrent Neural Networks



e.g. Image Captioning image -> sequence of words










Recurrent Neural Networks



e.g. **Sentiment Classification** sequence of words -> sentiment










Recurrent Neural Networks



e.g. Machine Translation seq of words -> seq of words










Recurrent Neural Networks














Vanilla Neural Network




























$$h_t = f_W(h_{t-1}, x_t)$$

$$h_t = \tanh(W_{hh}h_{t-1} + W_{hx}x_t)$$

EARNING BRASIL SUMMER SCHOOL







OFASAM

$$h_{t-1} = \begin{bmatrix} h_{t-1}^{0} \\ \vdots \\ h_{t-1}^{i} \end{bmatrix} \xrightarrow{h_{t}} \begin{bmatrix} h_{t}^{0} \\ \vdots \\ h_{t}^{i} \end{bmatrix}$$

$$W_{hh} = \begin{bmatrix} w_{00} & \cdots & w_{0i} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ii} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times i}$$

$$W_{hx} = \begin{bmatrix} w_{00} & \cdots & w_{0j} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ij} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times j}$$

$$x_{t} = \begin{bmatrix} x_{t}^{0} \\ \vdots \\ x_{t}^{j} \end{bmatrix}$$

$$h_{t} = \tanh([W_{hh}h_{t-1}] + W_{hx}x_{t})$$

$$h_t = \tanh(W_{hh}h_{t-1} + W_{hx}x_t)$$

$$W_{hh} = \begin{bmatrix} w_{00} & \cdots & w_{0i} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ii} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times i}$$

$$\uparrow \\
x_t = \begin{bmatrix} x_t^0 \\ \vdots \\ x_t^j \end{bmatrix}$$

$$W_{hx} = \begin{bmatrix} w_{00} & \cdots & w_{0j} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ij} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times j}$$

$$h_t = \tanh([W_{hh} \quad W_{hx}] \begin{bmatrix} h_{t-1} \\ \chi_t \end{bmatrix})$$










RNN



http://colah.github.io/posts/2015-08-Understanding-LSTMs/









NLP com RNNs

 Se colocarmos um softmax na saída da RNN mapeando cada possível palavra:

$$y_t = softmax(W_{hy}h_t)$$

• Teoricamente:

$$\widehat{P}(x_{t+1}|x_t,\dots,x_0) = y_t$$









#SQN

Como vamos aplicar o Backpropagation na RNN?











$$\frac{\partial E}{\partial W} = \sum_{t=1}^{T} \frac{\partial E_t}{\partial W}$$

$$\frac{\partial E_t}{\partial W} = \sum_{k=1}^t \frac{\partial E_t}{\partial y_t} \frac{\partial y_t}{\partial h_t} \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W}$$









Backpropagation Through Time (BPTT)

$$\frac{\partial E}{\partial W} = \sum_{t=1}^{T} \frac{\partial E_t}{\partial W}$$

$$\frac{\partial E_t}{\partial W} = \sum_{k=1}^t \frac{\partial E_t}{\partial y_t} \frac{\partial y_t}{\partial h_t} \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W}$$

























$$\frac{\partial E_t}{\partial W} = \sum_{k=1}^t \frac{\partial E_t}{\partial y_t} \frac{\partial y_t}{\partial h_t} \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W}$$



Lembrando que:


$$W_{hh}^{t-3}$$











$$\bigvee_{w_{hx}^{t-2}} W_{hx}^{t-2}$$





$$\frac{\partial h_t}{\partial h_k} = \prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}}$$














Se o gradiente = 1:

OK

Se o gradiente > 1:

Exploding gradients

Se o gradiente < 1:

Vanishing gradients














Ainda tem onde piorar

Se tivermos **múltiplas saídas**, Teremos **múltiplos gradientes**









- Problemas:
 - Treino ruidoso devido ao Vanishing/Exploding gradiente
 - Clipping pode ajudar
 - Dificuldade em lidar com dependências de longo prazo
 - João entrou na sala. José também. Já é tarde e ambos estão atrasados. João disse oi para
 - Dificuldade em lidar com ruído
- Teoricamente funciona, mas na prática é difícil treinar para problemas complexos










LSTM - Long Short Term Memory [Hochreiter et al., 1997]












Cell state

Resolve o problema do Vanishing/Exploding gradiente

É mais do que uma simples conexão direta, pois as informações propagadas são ponderadas pelas entradas a cada tempo











Forget Gate


Decide qual informação que vem do **estado anterior** vai ser jogada fora

1 : "Mantenha isso completamente"

0 : "Esqueça isso completamente"

Exemplo:

Ao ler um novo substantivo a rede pode **esquecer** o gênero do substantivo recebido anteriormente



$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right)$$











Input Gate


Decide qual informação que vem da **entrada** vai ser inserida É combinado com o candidato a novo C

1 : "Insira isso completamente"

0 : "Deixe de lado"

Exemplo:

Ao ler um novo substantivo a rede pode **memorizar** o gênero



$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C$$












Cell Update

Multiplica-se o estado anterior por f_t , esquecendo algumas informações.

Então adiciona-se $i_t * \tilde{C}_t$, que é o novo candidato **ponderado por quanto queremos lembrar**

Exemplo:

Repassa ao estado celular o novo gênero encontrado



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$












Output Gate

Primeiro determina-se quais partes do cell state será enviado para a saída.

Então usa-se uma tanh para gerar saídas que serão multiplicadas pelo o_t

Exemplo:

Prediz que a próxima palavra irá seguir o novo gênero



$$h_t = o_t * \tanh\left(C_t\right)$$










GRU

- Gated Recurrent Unit [Cho et al., 2014]
- Combina o input e forget gate no update gate
- Não possui cell state



$$z_{t} = \sigma (W_{z} \cdot [h_{t-1}, x_{t}])$$

$$r_{t} = \sigma (W_{r} \cdot [h_{t-1}, x_{t}])$$

$$\tilde{h}_{t} = \tanh (W \cdot [r_{t} * h_{t-1}, x_{t}])$$

$$h_{t} = (1 - z_{t}) * h_{t-1} + z_{t} * \tilde{h}_{t}$$







PFASAM

LSTM vs GRU

LSTM

- Mais parâmetros
 - $4(h(x+1)+h^2)$
- Maior custo
- Treino mais "complicado"
- Maior capacidade de combinar informações de formas diferentes

GRU


- Menos parâmetros
 - $3(h(x+1)+h^2)$
- Treino mais fácil
- Apresenta desempenho semelhante a LSTM em várias tarefas

Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling


Junyoung Chung

Caglar Gulcehre Université de Montréal KyungHyun Cho

Yoshua Bengio Université de Montréal CIFAR Senior Fellow



(a) Long Short-Term Memory



(b) Gated Recurrent Unit

LEARNING BRA SUMMER SCHOOL



OFASAM









LSTM vs GRU


RNN



LSTM







www.deeplearningbras









Aplicações

- Dados que possuam dependência temporal
 - NLP, áudio, vídeo, sinais, etc.
- Exemplos de aplicações recentes:
 - Análise de Sentimento
 - Tradução
 - Descrição de imagens
 - Q&A
 - Chatbots









Seq2Seq - Cho, 2014

- Formula a ideia de Encoder-Decoder recorrente para modelar relação entre sequências.
- Inicialmente proposto para tradução
- Artigo também introduz a GRU
- Pode ser usado em:
 - Tradução
 - Q&A (Question & Anwser)
 - Resumo de texto

Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation

Kyunghyun Cho

Bart van Merriënboer Caglar Gulcehre

Université de Montréal

firstname.lastname@umontreal.ca

Dzmitry Bahdanau

Jacobs University, Germany

d.bahdanau@jacobs-university.de

Fethi Bougares Holger Schwenk

Yoshua Bengio

Université du Maine, France Université de Montréal, CIFAR Senior Fellow

firstname.lastname@lium.univ-lemans.fr

find.me@on.the.web











Seq2Seq

- Na mesma época houve outro artigo propondo uma ideia semelhante
- Usa LSTM
- Propõe a inversão das sequências de saída

Sequence to Sequence Learning with Neural Networks

Ilya Sutskever Google ilyasu@google.com Oriol Vinyals
Google
vinyals@google.com

Quoc V. Le Google qv1@qoogle.com









Seq2seq

- Ideia:
 - Ao processar uma sequência uma rede recorrente tem a capacidade de armazenar a informação contida em um novo espaço dimensional.










Seq2seq

- Ideia:
 - Ao processar uma **sequência** uma rede recorrente tem a capacidade de **armazenar a informação** contida em um novo espaço dimensional.
 - Auto-encoder














Seq2Seq

- Então vamos passar essa memória para outra rede recorrente (Decoder) que irá construir uma sequência com base nessa memória, mapeando sequências com sequências (Seq2Seq)
- A memória se torna uma entrada condicional para o Decoder












Seq2seq

O estado s_t do Decoder é computado por:

$$s_t = f(s_{t-1}, y_{t-1}, c)$$











Seq2seq


Temos duas redes diferentes

Encoder:

 É treinado para compreender as sequências de entradas e registrar a informação em seu estado interno

Decoder:

 É treinado para compreender as saídas e decodificar a informação recebida como condicional












Seq2seq

Encoder recebe entradas de tamanho variável



 Decoder utiliza sua última saída para gerar a próxima saída, gerando assim saídas de tamanho também variável











Seq2Seq

- Problemas
 - Dificuldade com sequências longas
 - Fortemente dependente do tamanho do estado do encoder











Attention [Bahdanau, 2014]

- Seq2seq com atenção
 - Propõe um mecanismo de atenção para transmitir os estados do Encoder

NEURAL MACHINE TRANSLATION
BY JOINTLY LEARNING TO ALIGN AND TRANSLATE

Dzmitry Bahdanau

Jacobs University Bremen, Germany

KyungHyun Cho Yoshua Bengio* Université de Montréal

- Permite que o Decoder "preste atenção" em partes mais importantes da entrada e "ignore" palavras irrelevantes
- Estado da arte para mapear sequências












Bidirectional LSTM - BiLSTM












- BiLSTM
- Usa a média ponderada dos estados do Encoder
- $s_t = f(s_{t-1}, y_{t-1}, c_t)$
- $c_i = \sum_{j=1}^T \alpha_{ij} h_j$
- $\alpha_{ij} = softmax(e_{ij})$
- $e_{ij} = f_{att}(s_{i-1}, h_j)$ modelo de alinhamento = MLP
 - $f_{att}(s_{i-1}, h_j) = \mathbf{v}_a^\mathsf{T} \tanh(W_a[s_{i-1}, h_j])$
- A energia e reflete a importância da anotação do estado h_j com respeito ao estado anterior do Decoder s_{i-1} em decidir o próximo estado s_i e a próxima saída y_i
- Assim o Decoder decide em qual parte do input deve prestar atenção















































DEEP LEARNING BRASIL SUMMER SCHOOL











Alinhamento













Resumindo

- RNN:
 - Comprimir sequências
 - Transferir informações
 - Gerar sequências
- Mecanismo de Atenção:
 - Seleção de inputs







PFASAM


Seq2seq – Evolução GNMT - 2016

- Conexões residuais
- Quebra as palavras em "subpalavras"
- Várias otimizações

Google's Neural Machine Translation System: Bridging the Gap between Human and Machine Translation

Yonghui Wu, Mike Schuster, Zhifeng Chen, Quoc V. Le, Mohammad Norouzi yonghui,schuster,zhifengc,qvl,mnorouzi@google.com

Wolfgang Macherey, Maxim Krikun, Yuan Cao, Qin Gao, Klaus Macherey, Jeff Klingner, Apurva Shah, Melvin Johnson, Xiaobing Liu, Łukasz Kaiser, Stephan Gouws, Yoshikiyo Kato, Taku Kudo, Hideto Kazawa, Keith Stevens, George Kurian, Nishant Patil, Wei Wang, Cliff Young, Jason Smith, Jason Riesa, Alex Rudnick, Oriol Vinyals, Greg Corrado, Macduff Hughes, Jeffrey Dean












PFASAM

Seq2seq – Evolução GNMT - 2017

- Mesmo modelo
- Treino realizado com múltiplos idiomas
- Tokens indicam qual deve ser o idioma de saída
- Sugere evidências de uma "Interlingua"

Google's Multilingual Neural Machine Translation System: Enabling Zero-Shot Translation

Melvin Johnson, Mike Schuster, Quoc V. Le, Maxim Krikun, Yonghui Wu,
Zhifeng Chen, Nikhil Thorat
melvinp,schuster,qvl,krikun,yonghui,zhifengc,nsthorat@google.com
Fernanda Viégas, Martin Wattenberg, Greg Corrado,
Macduff Hughes, Jeffrey Dean





®FASAM








Tradução sem pares

- Trabalho que irá ser publicado no ICLR 2018
- Usa o conceito de redes adversárias para treinar seg2seg com frases "corrompidas" com palavras traduzidas
- Alcançou resultados razoáveis na hora de cruzar um encoder de uma língua com um decoder de outra

Unsupervised Machine Translation USING MONOLINGUAL CORPORA ONLY

Guillaume Lample * † , Ludovic Denoyer † , Marc'Aurelio Ranzato * * Facebook AI Research.

† Sorbonne Universités, UPMC Univ Paris 06, LIP6 UMR 7606, CNRS {ql,ranzato}@fb.com,ludovic.denoyer@lip6.fr



DEEP LEARNING BRASIL SUMMER SCHOOL



PFASAM








Show, Attend and Tell: Neural Image Caption Generation with Visual Attention [Xu, 2015]



A woman is throwing a frisbee in a park.



A dog is standing on a hardwood floor.





A little girl sitting on a bed with a teddy bear.



A group of <u>people</u> sitting on a boat in the water.



A giraffe standing in a forest with trees in the background.










Lip Reading Sentences in the Wild [Chung, 2017]



DEEP LEARNING BRASIL SUMMER SCHOOL









PFASAM

AttnGan [Xu, 2017]

Microsoft researchers build a bot that draws what you tell it to

Jan 18, 2018 | John Roach















Muito Obrigado

Rafael Teixeira rafaelts777@gmail.com